



Impacto del clima en la puntualidad de vuelos

El peso relativo del clima frente a otros factores operativos en la puntualidad de vuelos domésticos de Estados Unidos, primer trimestre de 2025

Trabajo Final de Máster, Data & Analytics

María González

github.com/mgonzalezbenm/vuelos-clima-eda

2026

1. Resumen ejecutivo

Cuando un vuelo se retrasa, la primera explicación que viene a la cabeza suele ser el tiempo: nieve, tormentas, viento fuerte en pista. Es una explicación intuitiva y, hasta cierto punto, correcta. Este trabajo la pone a prueba con datos: un trimestre completo de vuelos domésticos en Estados Unidos, cruzado día a día con el clima registrado en el aeropuerto de origen de cada vuelo.

La respuesta corta es que el clima sí importa, y la nieve en particular, pero está lejos de ser la explicación principal. A nivel descriptivo el efecto es contundente: la puntualidad cae de 80,8% a 56,4% en jornadas con nieve, casi 25 puntos porcentuales de diferencia. Sin embargo, al someter esa relación a un análisis estadístico riguroso, su tamaño de efecto resulta pequeño, del mismo orden que el de la aerolínea, y claramente por debajo del factor que más pesa de todos los estudiados: la franja horaria en la que despegue el vuelo. Los tests aplicados son significativos en todos los casos ($p < 0,001$), pero con más de un millón de observaciones eso es, sobre todo, una consecuencia del tamaño muestral, no una prueba de que el clima domine sobre el resto de variables.

El análisis se apoya en cuatro notebooks documentados, un dataset final de 1.138.858 filas y 49 columnas construido a partir de dos fuentes independientes, y un dashboard en Power BI que permite explorar los resultados de forma interactiva por aerolínea, franja horaria y condición climática. Las páginas siguientes explican cómo se ha llegado a esas cifras, qué decisiones metodológicas se han tomado por el camino y qué se puede hacer, en la práctica, con lo que se ha encontrado.

2. Introducción y contexto

La puntualidad de los vuelos no es solo una cuestión de comodidad para el pasajero. Un retraso se traduce en costes directos para la aerolínea (tripulaciones que exceden su turno, conexiones perdidas, compensaciones), en fricción operativa para el aeropuerto (huecos de pista que dejan de aprovecharse, reasignación de puertas de embarque) y, agregado a lo largo de una red, en un efecto de bola de nieve: el retraso de un avión en Chicago puede acabar retrasando un vuelo distinto en Nueva York si comparte aeronave o tripulación.

Entender qué explica realmente esos retrasos, más allá de la intuición, tiene un valor práctico concreto: permite decidir dónde merece la pena invertir en mitigación (deshielo, personal de contingencia, ajustes de planificación horaria) y dónde no. Si el clima explicara la mayor parte de la variabilidad, la respuesta sería sencilla: invertir en previsión meteorológica y protocolos de contingencia. Si, como sugiere este análisis, el clima es solo una pieza más de un puzzle con muchas piezas, la respuesta tiene que ser necesariamente más matizada.

El alcance de este trabajo se limita a un trimestre (enero a marzo de 2025) y a 35 aeropuertos de origen, seleccionados por concentrar el 69,2% del tráfico total del periodo. Es una limitación deliberada: permite mantener un volumen de datos manejable sin perder representatividad sobre la operación real del sistema.

3. Pregunta de negocio y objetivos

La pregunta que articula todo el proyecto es la siguiente:

¿En qué medida el clima adverso explica los retrasos y cancelaciones de vuelos, frente a otros factores como la aerolínea, la franja horaria o el día de la semana?

De ahí se derivan los objetivos concretos del trabajo: auditar y limpiar dos fuentes de datos con problemas reales de calidad, unirlos en un único dataset fiable, cuantificar con estadística descriptiva e inferencial el peso relativo de cada factor, construir un dashboard que haga esos resultados explorables por quien no ha tocado el código, y valorar si el enfoque seguido tendría sentido aplicado a un contexto europeo, con Eurocontrol o Aena como referencia.

4. Fuentes de datos

El proyecto combina dos fuentes independientes, unidas por el código IATA del aeropuerto de origen y la fecha del vuelo. Ambas tienen particularidades que conviene conocer antes de interpretar cualquier resultado.

Dataset	Fuente	Volumen	Contenido
Reporting Carrier On-Time Performance (3 CSV, enero 2025)	BTS TranStats	~500-600 mil filas/mes, 110 columnas originales	Horarios, retrasos, causas de retraso, cancelaciones y desvíos, vuelo a vuelo
Clima diario por aeropuerto	meteostat 1.7.6 (API clásica)	Diario, 35 aeropuertos, 11 variables	Temperatura, precipitación, viento, presión, nieve
Coordenadas de aeropuertos (apoyo)	OurAirports	333 códigos IATA	Latitud/longitud para geolocalizar cada aeropuerto

El BTS publica sus datos mensualmente y con un desfase de varias semanas respecto al cierre del mes, lo que en la práctica fija el trimestre analizado como el más reciente disponible en el momento de arrancar el proyecto. Una particularidad del propio formato merece mención aparte: las columnas de causa de retraso (CarrierDelay, WeatherDelay, NASDelay, SecurityDelay, LateAircraftDelay) solo se rellenan cuando el retraso en llegada alcanza los 15 minutos; por debajo de ese umbral quedan vacías, no porque falte el dato sino porque el BTS considera que no aplica. Confundir esa ausencia con un valor perdido habría distorsionado cualquier análisis posterior.

La API de meteostat empleada (1.7.6, interfaz clásica basada en Point y Daily) está marcada como versión heredada por el propio proyecto, que ha migrado a un enfoque distinto en versiones más recientes; se optó por mantenerla por su estabilidad documental en el momento de desarrollo, y queda anotado como riesgo a vigilar si el proyecto se retoma más adelante.

Los tres CSV del BTS pesan individualmente más de 100 MB y no se incluyen en el repositorio de GitHub por límite de tamaño; su descarga está documentada en el README. El clima y las coordenadas de apoyo sí están versionados en el repositorio.

5. Metodología

El trabajo sigue cuatro fases, cada una recogida en un notebook independiente y ejecutadas en orden estricto, porque cada una depende de las decisiones tomadas en la anterior:

Auditoría inicial → Limpieza y transformación → Unión vuelos + clima → Análisis descriptivo y estadística inferencial

5.1. Auditoría y limpieza

Antes de limpiar nada se auditó qué tipo de nulo era cada nulo, porque no todos significan lo mismo. TaxiOut, TaxiIn, AirTime y ArrTime aparecen vacíos solo en vuelos cancelados o desviados: no falta el dato, es que ese dato no llegó a producirse, y tratarlo como un hueco a rellenar habría sido un error conceptual antes que técnico. Por eso no se imputan, y el análisis de retrasos se restringe desde el principio a vuelos en estado normal.

Un caso similar es el de 111 vuelos con hora de salida registrada pero sin retraso de salida calculado; revisados uno a uno resultaron ser, en su totalidad, vuelos cancelados después del despegue. El campo Tail_Number falta en 4.102 registros, siempre también en cancelados; se ha dejado tal cual, aunque se valora excluir esos registros de futuras versiones del dataset si llegan a introducir ruido en algún modelo posterior.

Los horarios en formato HHMM se convirtieron a minutos desde medianoche para poder operar con ellos numéricamente, con la salvedad de que 2400 se traduce como 0 (medianoche del día siguiente, no las 24 horas). ArrMin se anula específicamente en los vuelos desviados, porque en ese caso el avión aterriza en un aeropuerto distinto al de destino previsto y esa hora dejaría de ser comparable con el resto de la muestra.

El tratamiento de los retrasos extremos merece una mención propia. Existen vuelos con retrasos de hasta 3.400 minutos, más de 56 horas. La tentación habitual sería tratarlos como errores de carga y eliminarlos, pero una revisión de esos casos concretos no encontró indicios de que lo fueran: son retrasos reales, extremos pero reales. Se optó por conservarlos y neutralizar su impacto en el análisis mediante el uso de mediana y percentiles en lugar de la media, tests no paramétricos que no asumen normalidad, y un indicador adicional (retraso_extremo, definido como más de 300 minutos) pensado específicamente para análisis de sensibilidad.

5.2. Tratamiento de la variable de nieve

La variable snow_orig de meteostat presenta un patrón de nulos que no es aleatorio: faltan sistemáticamente en aeropuertos donde apenas nieva nunca, como Honolulu, Los Ángeles, San Francisco o Sacramento. Imputar esos huecos con cero habría sido razonable a primera vista, pero habría introducido un sesgo sutil: asumir ausencia de nieve donde en realidad el dato simplemente no se mide con fiabilidad. En su lugar se construyó una variable proxy, nieve_aprox, definida como la combinación de precipitación positiva y temperatura media igual o inferior a cero grados, que aproxima la presencia de nieve sin depender del campo original. Las columnas wdir, wpgt y tsun se descartaron directamente por venir vacías en el 100% de los registros.

5.3. Unión de las dos fuentes

El cruce entre vuelos y clima se realizó mediante un merge de tipo m:1 (muchos vuelos por cada combinación de aeropuerto y fecha, un único registro de clima), validado explícitamente con la columna auxiliar `_merge` de pandas para descartar pérdida o duplicación de filas. El resultado es el dataset final: 1.138.858 filas y 49 columnas, guardado en formato Parquet para mantener un tamaño de archivo manejable frente al CSV equivalente.

5.4. Elección de los tests estadísticos

Dado que las variables de retraso están fuertemente sesgadas hacia la derecha, con una cola larga de valores extremos, se descartaron los tests paramétricos clásicos (t de Student, ANOVA) a favor de sus equivalentes no paramétricos: Mann-Whitney U para comparar dos grupos, Kruskal-Wallis para más de dos, correlación de Spearman para relaciones monótonas entre variables continuas, y chi-cuadrado con V de Cramér para variables categóricas como la cancelación.

Con un tamaño muestral superior al millón de observaciones, prácticamente cualquier diferencia, por pequeña que sea, alcanza significancia estadística convencional. Por ese motivo el criterio de decisión de este trabajo no es el valor p, sino el tamaño del efecto: r de rango biserial para Mann-Whitney, rho de Spearman, épsilon al cuadrado para Kruskal-Wallis y V de Cramér para chi-cuadrado, interpretados según los umbrales convencionales de la literatura (Cohen, 1988): un efecto en torno a 0,1 se considera pequeño, en torno a 0,3 moderado y por encima de 0,5 grande.

6. Resultados del análisis descriptivo

La puntualidad global de los vuelos en estado normal, entendida como retraso de llegada inferior a 15 minutos, se sitúa en el 79,8%, con una mediana de retraso de -7 minutos: la mitad de los vuelos llegan, de hecho, algo antes de lo previsto. Las cancelaciones representan el 1,74% del total y los desvíos el 0,25%, cifras que sitúan al conjunto de vuelos con incidencias graves por debajo del 2%.

Entre aerolíneas la diferencia es notable: del 69,8% de puntualidad de OH al 83,7% de HA, casi 14 puntos de distancia entre la peor y la mejor. Pero el factor que más se nota a simple vista en los datos descriptivos no es la aerolínea, sino la franja horaria del vuelo: 91,2% de puntualidad en vuelos de madrugada frente a un 74,8% en los de la noche. El día de la semana también deja huella, aunque de forma más discreta, con martes y miércoles ligeramente mejores y domingo como el peor día para volar si la puntualidad es la prioridad.

El clima, por su parte, se comporta exactamente como cabría esperar en la dirección del efecto: con clima adverso la puntualidad cae de 81,8% a 67,9%. Cuando ese clima adverso incluye nieve, la caída se agrava sensiblemente, hasta el 56,4% frente al 80,8% sin nieve, la brecha más amplia de todo el análisis descriptivo. Las cancelaciones reaccionan todavía con más intensidad: se multiplican por cuatro tanto con clima adverso (4,93% frente a 1,19%) como con nieve (6,01% frente a 1,56%), lo que indica que ante mal tiempo las aerolíneas prefieren cancelar antes que arriesgarse a un retraso descontrolado.




Figura 1. Distribución del retraso según presencia de clima adverso




Figura 2. Porcentaje de puntualidad por franja horaria




Figura 3. Porcentaje de cancelación según clima adverso y nieve




Figura 4. Relación entre retraso y precipitación en origen

7. Resultados de estadística inferencial

Todos los contrastes aplicados resultan significativos tras corregir por comparaciones múltiples mediante FDR ($p < 0,001$ en todos los casos), un resultado esperable con un tamaño muestral de más de un millón de vuelos. La tabla siguiente recoge, para cada relación estudiada, el tamaño de efecto correspondiente:

Test	Relación	Tamaño de efecto
Mann-Whitney	ArrDelay ~ clima_adverso	$r = 0,108$
Mann-Whitney	ArrDelay ~ nieve_aprox	$r = 0,105$
Spearman	ArrDelay ~ prcp_orig	$\rho = 0,137$
Spearman	ArrDelay ~ wspd_orig	$\rho = 0,069$
Spearman	ArrDelay ~ pres_orig	$\rho = -0,029$
Spearman	ArrDelay ~ tavg_orig	$\rho = -0,005$ (no relevante)
Kruskal-Wallis	ArrDelay ~ franja_hora	$\epsilon^2 = 0,0161$ (el mayor de todos)
Kruskal-Wallis	ArrDelay ~ dia_semana	$\epsilon^2 = 0,0096$
Kruskal-Wallis	ArrDelay ~ Reporting_Airline	$\epsilon^2 = 0,0065$ (el menor, pese a 14 grupos)
Chi-cuadrado	cancelación ~ clima_adverso	$V = 0,101$
Chi-cuadrado	cancelación ~ Reporting_Airline	$V = 0,090$

Comparados con los umbrales de referencia de Cohen, todos estos efectos se sitúan en la categoría de pequeño (en torno a 0,1) o incluso por debajo. Ninguno se acerca al rango moderado. Dentro de ese conjunto, la franja horaria es sistemáticamente el factor con mayor peso relativo, por delante incluso de la nieve, y la aerolínea, pese a agrupar 14 categorías distintas (lo que normalmente infla el estadístico de Kruskal-Wallis), es el que menos explica.

Nota técnica: con más de un millón de filas, `scipy.stats.mannwhitneyu` puede devolver un p-valor de 0.0 por desbordamiento de precisión numérica en la representación en punto flotante. El tamaño del efecto r debe calcularse a partir del propio estadístico U ($z = (U - n_1n_2/2) / \text{raíz}(n_1n_2(n+1)/12)$), nunca invirtiendo el p-valor para derivarlo, porque un p-valor truncado a 0.0 arrastraría ese error al cálculo.

8. Discusión de resultados

Puestos uno junto a otro, el análisis descriptivo y el inferencial cuentan historias que a primera vista parecen contradictorias, y que en realidad no lo son. El descriptivo muestra una brecha de casi 25 puntos en puntualidad entre días con y sin nieve, una diferencia que cualquiera reconocería como relevante en un informe ejecutivo. El inferencial, en cambio, reduce esa misma relación a un tamaño de efecto pequeño. Ambas cosas son ciertas a la vez: la nieve empeora la puntualidad de forma visible y consistente, pero por sí sola deja sin explicar la inmensa mayoría de la variabilidad del retraso.

Esa aparente paradoja tiene una lectura razonable. El retraso de un vuelo concreto depende de una cadena de causas que rara vez se reduce a una sola: la aeronave que opera ese vuelo puede llegar tarde de un trayecto anterior, la tripulación puede estar cerca de agotar sus horas de servicio, el aeropuerto de destino puede estar congestionado a la hora de llegada, y el clima es solo uno más de esos eslabones. En un sistema tan interconectado como la red aérea, ningún factor aislado tiene por qué explicar gran parte de la varianza, y el hecho de que ni siquiera la franja horaria, el factor con mayor peso encontrado en este trabajo, supere un tamaño de efecto pequeño, refuerza esa lectura.

Dicho de otro modo: preguntar cuánto retraso explica el clima es, en cierto sentido, la pregunta equivocada si se espera una respuesta que por sí sola justifique una decisión operativa. La pregunta más útil es en qué medida el clima, combinado con la franja horaria y la aerolínea, permite anticipar los episodios de peor desempeño, y esa es precisamente la línea de trabajo que se propone más adelante.

9. Dashboard interactivo (Power BI)

El dashboard, disponible en `dashboard/vuelos_clima_dashboard.pbix`, traslada estos resultados a un formato que no exige tocar código para explorarlo. Incluye cinco bloques:

- KPIs generales: porcentaje de puntualidad, de cancelados, de desviados, total de vuelos y retraso medio.
- Mapa de los 35 aeropuertos de origen, con el volumen de tráfico representado por el tamaño de cada burbuja.
- Evolución de vuelos y puntualidad a lo largo del trimestre, con jerarquía de fecha y drill-down de mes a día: a nivel mensual se aprecia con claridad cómo volumen y puntualidad caen juntos en febrero, el mes con más nieve, y se recuperan en marzo.

- Puntualidad por franja horaria, que traslada al dashboard el factor con mayor peso relativo de todo el análisis inferencial.
- Segmentadores por aerolínea y por clima adverso, que filtran el resto de visuales de forma simultánea.




Figura 5. Captura del dashboard completo, sin ningún filtro aplicado

10. Conclusiones y recomendaciones

De la discusión anterior se derivan implicaciones prácticas razonablemente concretas, pensadas para quien tenga que decidir dónde invertir esfuerzo operativo:

- La nieve es, con diferencia, el factor climático que de verdad pesa; la lluvia o el viento apenas mueven la aguja en comparación. Si hay que priorizar recursos de contingencia (equipos de deshielo, personal extra, reprogramación preventiva), tiene más sentido concentrarlos en los aeropuertos y meses con nieve que diseñar un protocolo genérico de clima adverso que trate por igual la lluvia y la nevada.
- La franja horaria pesa más que cualquier variable climática analizada. Cualquier plan de mejora de la puntualidad que no toque la planificación de horarios, por ejemplo evitar acumular salidas en la franja nocturna, deja sobre la mesa la palanca individual más grande de todas las estudiadas.
- Ningún factor aislado explica el problema, así que cualquier modelo de predicción de retrasos que mire solo el clima, o solo la aerolínea, se quedará corto casi con seguridad. La vía razonable es combinar clima, franja horaria y aerolínea en un mismo modelo, y no tratarlos como explicaciones alternativas.

- La cancelación es notablemente más sensible al clima que el propio retraso, multiplicándose por cuatro en presencia de mal tiempo. Esto sugiere que las aerolíneas ya aplican, de facto, un criterio conservador ante el clima adverso que no se refleja del todo en las cifras de retraso medio, y que merecería un análisis específico de los protocolos de decisión de cancelación.

11. Limitaciones

Además de las ya mencionadas sobre la fiabilidad de `snow_orig`, conviene señalar varias limitaciones adicionales que acotan el alcance de las conclusiones.

El clima se mide a nivel diario y por aeropuerto, no a la hora concreta del despegue o el aterrizaje. Es posible que una tormenta breve de una o dos horas, suficiente para causar retrasos importantes, quede diluida en el promedio del día y no se refleje con precisión en variables como `prcp_orig` o `wspd_orig`. Esto tiende a subestimar, no a sobreestimar, el efecto real del clima puntual.

Los 35 aeropuertos analizados no son una muestra aleatoria, sino los de mayor volumen de tráfico; representan el 69,2% de los vuelos del trimestre, pero el 30,8% restante corresponde a aeropuertos más pequeños que podrían comportarse de forma distinta, por ejemplo con menor capacidad de absorber picos de demanda o menos infraestructura de deshielo.

Por último, y es probablemente la limitación más importante de todas: este es un análisis de asociación, no de causalidad. Que el clima se relacione estadísticamente con el retraso no implica que el resto de los factores relevantes, como la congestión de la red, la disponibilidad de tripulaciones o el mantenimiento de las aeronaves, estén controlados en la comparación. Un único trimestre tampoco permite extraer conclusiones sobre estacionalidad interanual ni sobre si el patrón observado en el invierno de 2025 se repite con regularidad.

12. Líneas futuras de trabajo

- Construir un modelo multivariante (por ejemplo, una regresión con regularización o un modelo de árboles) que combine clima, franja horaria, aerolínea y día de la semana, en lugar de analizarlos por separado, para estimar su efecto conjunto sobre el retraso.
- Incorporar datos climáticos con mayor resolución temporal, si están disponibles, para capturar episodios meteorológicos breves que el promedio diario actual podría estar diluyendo.
- Automatizar la descarga y actualización trimestral de los datos del BTS mediante un script (`src/descargar_datos.py`), de forma que el análisis pueda repetirse sobre trimestres sucesivos y permitir así, con el tiempo, hablar de estacionalidad interanual.
- Aplicar un post-hoc de Dunn con corrección de Bonferroni sobre la variable aerolínea en el test de Kruskal-Wallis, para identificar qué pares concretos de aerolíneas difieren de forma significativa; no es urgente, dado que el tamaño de efecto global ya indica una diferencia pequeña.

13. Metodología transferible a Eurocontrol / Aena

El proceso seguido (auditoría de calidad, limpieza documentada y justificada, unión de fuentes por aeropuerto y fecha, estadística descriptiva e inferencial centrada en el tamaño de efecto, y un dashboard operativo) no depende de ninguna particularidad propia del sistema estadounidense. Es aplicable, con ajustes menores, a datos de puntualidad europeos.

En el caso de Eurocontrol, el organismo publica estadísticas de retraso a nivel de red a través de su Network Manager, con una granularidad y una lógica de reporting distintas a las del BTS, pero perfectamente cruzables con clima si se dispone de las coordenadas de los aeropuertos europeos relevantes, algo que meteostat también cubre. En el caso de Aena, las estadísticas de puntualidad por aeropuerto español podrían combinarse con el mismo enfoque, sustituyendo el código IATA/ICAO según corresponda.

La diferencia más relevante para tener en cuenta no es metodológica sino estructural: el tráfico aéreo europeo tiene un componente transfronterizo mucho mayor que el doméstico estadounidense, con más aerolíneas operando rutas internacionales cortas y una red de control aéreo fragmentada entre países. Es razonable esperar que el peso relativo de cada factor (clima, franja horaria, aerolínea) varíe respecto a los resultados de este trabajo, aunque el propio proceso para medirlo sea el mismo.

14. Estructura del repositorio y reproducibilidad

El repositorio completo está disponible en:

- github.com/mgonzalezbenm/vuelos-clima-eda

Organización de carpetas:

```
data/raw/ (bts, clima, apoyo) · data/processed/ (dataset final)
notebooks/ (01_auditoria, 02_limpieza, 03_eda, 04_estadistica)
dashboard/ (vuelos_clima_dashboard.pbix, dashboard.pdf)
reports/figures/ · src/ · requirements.txt · README.md
```

El README.md del repositorio detalla el procedimiento completo de instalación, la descarga de los datos que no están versionados por tamaño, y el orden de ejecución de los notebooks, además de recoger el mismo listado de próximos pasos incluido en este informe.

15. Referencias

- Bureau of Transportation Statistics (BTS). Reporting Carrier On-Time Performance. Oficina de Estadísticas de Transporte de Estados Unidos. <https://www.transtats.bts.gov/>
- Meteostat Developers. Meteostat Python Library, versión 1.7.6, documentación de la API clásica. <https://dev.meteostat.net/>
- OurAirports. Base de datos abierta de aeropuertos y coordenadas. <https://ourairports.com/>

- Cohen, J. (1988). Statistical Power Analysis for the Behavioral Sciences (2ª ed.). Lawrence Erlbaum Associates. Referencia para los umbrales convencionales de interpretación de tamaño de efecto.
- Eurocontrol. Network Manager, estadísticas de puntualidad y retraso a nivel de red europea. <https://www.eurocontrol.int/>
- Aena. Estadísticas de tráfico aéreo y puntualidad por aeropuerto. <https://www.aena.es/>

16. Autora

María González, github.com/mgonzalezbenm